Acreditada
en Alta Calidad
Res. nº. 29499 del Mineducación.
29/12/17 vigencia 28/12/21

Informe explicativo Proyecto Final
DataXperience
Lina Kamila Sánchez Gómez
Sharick Yuliana Molina Guzmán
Camilo Arturo Pardo Rodriguez

Análisis de Factores que Influyen en el Riesgo de Extinción de Especies mediante Ciencia de Datos

En el desarrollo de este proyecto se implementó un análisis de datos utilizando el lenguaje de programación R, con el objetivo de comprender cómo ciertos factores ambientales influyen en el riesgo de extinción de diferentes especies; para ello, se estructuró un proceso que inicia con la preparación del entorno de trabajo, seguido de la construcción del dataset, el análisis exploratorio, la visualización de datos y finalmente la implementación de un modelo predictivo.

En primer lugar, se realizó la instalación y carga de las librerías necesarias, específicamente ggplot2 y dplyr; la elección de estas herramientas responde a su amplia utilización en ciencia de datos, ya que ggplot2 permite construir visualizaciones claras, personalizables y de alta calidad, lo cual es fundamental para comunicar hallazgos, mientras que dplyr facilita la manipulación y análisis de datos de forma eficiente; este paso es esencial, ya que establece las bases para todo el procesamiento posterior.

Posteriormente, se procedió a la creación del dataset utilizando la función data.frame; esta decisión metodológica se tomó con el fin de estructurar la información en formato tabular, donde cada fila representa una especie y cada columna una variable; en este caso, se incluyeron diez especies en vía de extinción y tres variables principales: población, pérdida de hábitat y caza ilegal; la selección de estas variables no es arbitraria, sino que responde a factores ampliamente reconocidos en estudios ambientales como determinantes en la disminución de la biodiversidad; aunque los datos son simulados, se construyeron de manera coherente con problemáticas reales, lo que permite desarrollar un análisis representativo.

Una vez definido el dataset, se realizó un análisis exploratorio mediante funciones como summary() y el cálculo de promedios; este paso es fundamental en cualquier flujo de ciencia de datos, ya que permite entender la estructura, distribución y comportamiento general de las variables antes de aplicar modelos más complejos; a través de este análisis se identificaron patrones iniciales, como altos porcentajes de pérdida de hábitat en varias especies y una gran variabilidad en las poblaciones, lo cual sugiere posibles relaciones entre las variables. A continuación, se desarrollaron diferentes visualizaciones utilizando la librería ggplot2; en primer lugar, se construyó un gráfico de barras mediante la función geom_bar, con el objetivo de comparar la población entre especies; este tipo de gráfico fue seleccionado porque permite una comparación clara y directa entre categorías, facilitando la identificación de especies con menor número de individuos y, por lo tanto, mayor vulnerabilidad.

Seguidamente, se implementó un histograma utilizando geom_histogram para analizar la distribución de la pérdida de hábitat; la elección de este gráfico se debe a que permite observar la frecuencia de los valores y detectar concentraciones en determinados rangos, evidenciando que muchas especies presentan niveles altos de degradación de su entorno natural. De igual forma, se utilizó un boxplot mediante geom_boxplot para analizar la variabilidad en la caza ilegal; este tipo de visualización es especialmente útil para identificar la dispersión de los datos, así como posibles valores atípicos, permitiendo entender cómo este factor afecta de manera distinta a cada especie.

Posteriormente, se calculó la matriz de correlación entre las variables numéricas utilizando la función cor(); este análisis permite cuantificar la relación entre las variables y sirve como base para justificar la implementación de un modelo predictivo, ya que evidencia si existe dependencia entre ellas. Una vez comprendido el comportamiento de los datos, se procedió a construir un modelo de regresión lineal utilizando la función lm(); la elección de este modelo se debe a su simplicidad e interpretabilidad, lo que lo convierte en una herramienta adecuada para analizar relaciones entre variables en un contexto académico; en este caso, la población se definió como la variable dependiente, mientras que la pérdida de hábitat y la caza ilegal se establecieron como variables independientes.

El modelo funciona mediante el ajuste de una ecuación lineal que busca minimizar la diferencia entre los valores observados y los valores estimados, utilizando el método de mínimos cuadrados; a través del comando summary(modelo) se obtiene un resumen estadístico que incluye los coeficientes de cada variable, los cuales indican la dirección y magnitud de su influencia; por ejemplo, un coeficiente negativo asociado a la pérdida de hábitat indicaría que un aumento en esta variable tiende a reducir la población, lo cual es coherente con la lógica ambiental del problema. Adicionalmente, se generó una visualización del modelo mediante un gráfico de dispersión con línea de regresión, utilizando geom_point y geom_smooth; esta representación permite observar de manera gráfica la relación entre la pérdida de hábitat y la población, evidenciando tendencias que respaldan los resultados del modelo.

Finalmente, se utilizó la función predict() para realizar una predicción bajo un escenario hipotético en el cual la pérdida de hábitat y la caza ilegal alcanzan niveles críticos; este paso es clave, ya que demuestra la capacidad del modelo para proyectar posibles escenarios futuros; los resultados obtenidos indican una disminución en la población bajo estas condiciones, lo que refuerza la idea de que el aumento en la presión ambiental tiene consecuencias directas sobre la supervivencia de las especies.

Resultados Gráficos

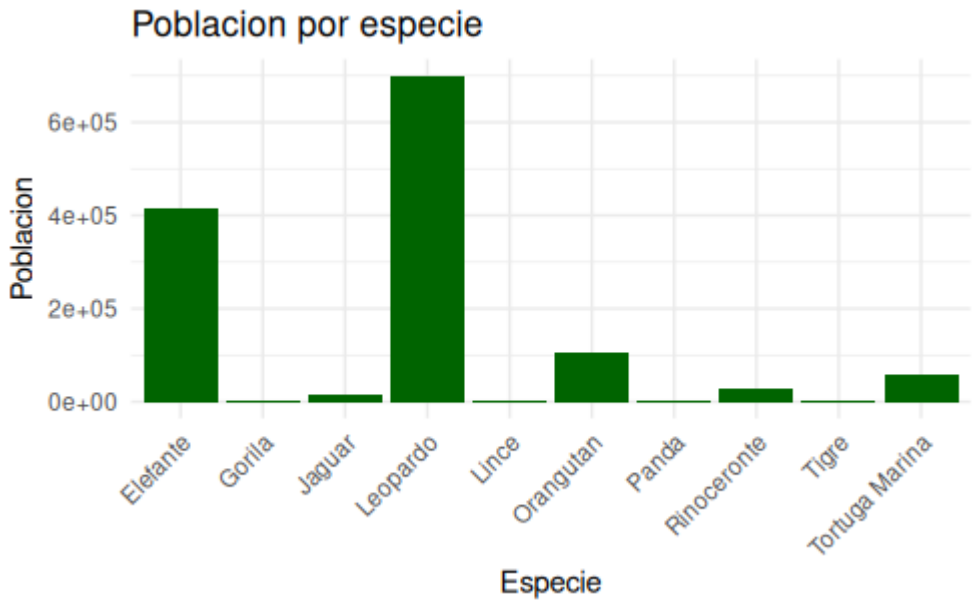
Poblacion por especie
Poblacion
6e+05
4e+05
2e+05
0e+00
Elefante
Gorila
Jaguar
Leopardo
Lince
Orangutan
Panda
Rinoceronte
Tigre
Tortuga Marina
Especie

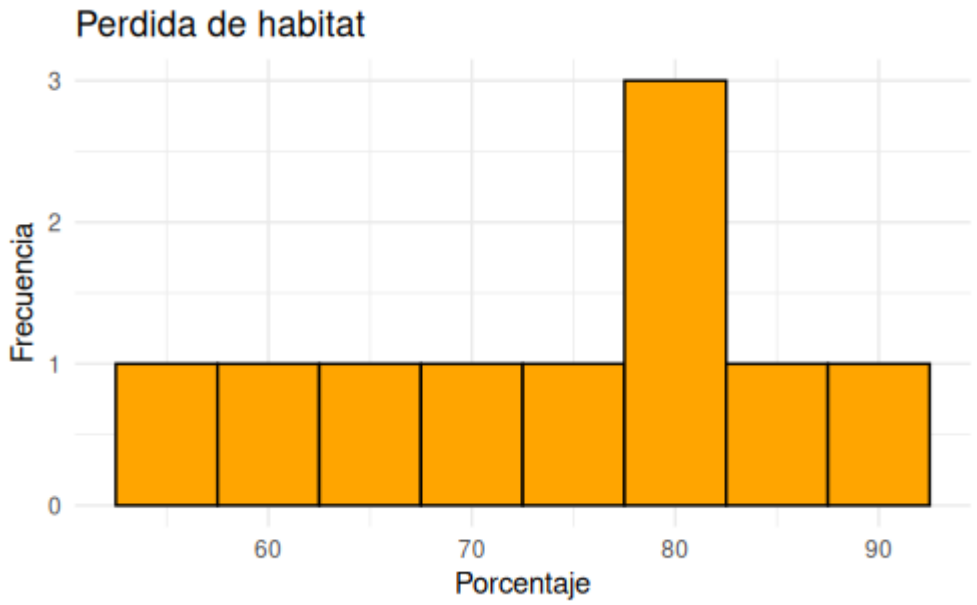
Perdida de habitat
Frecuencia
3
2
1
0
60
70
80
90
Porcentaje

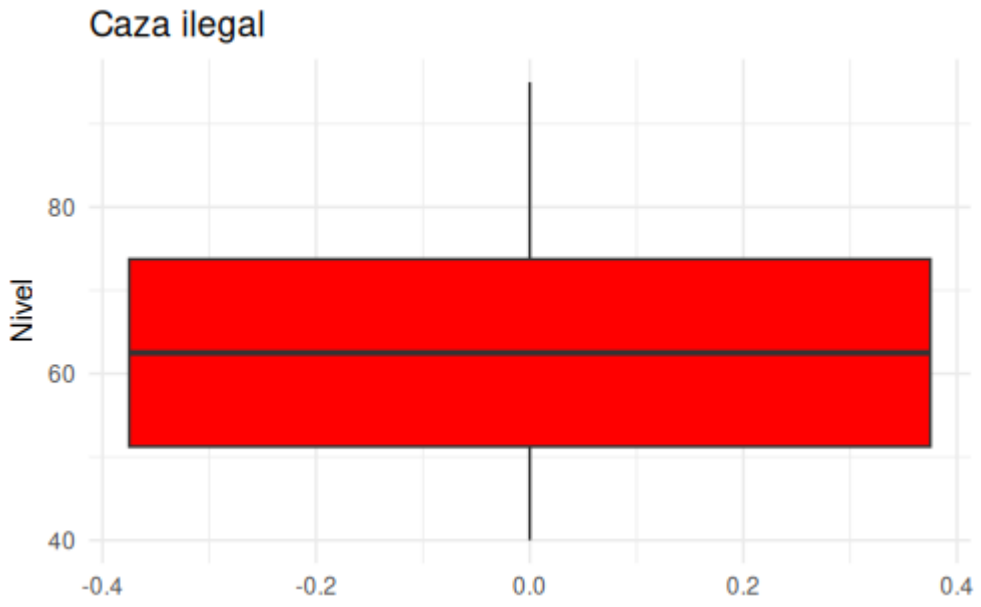

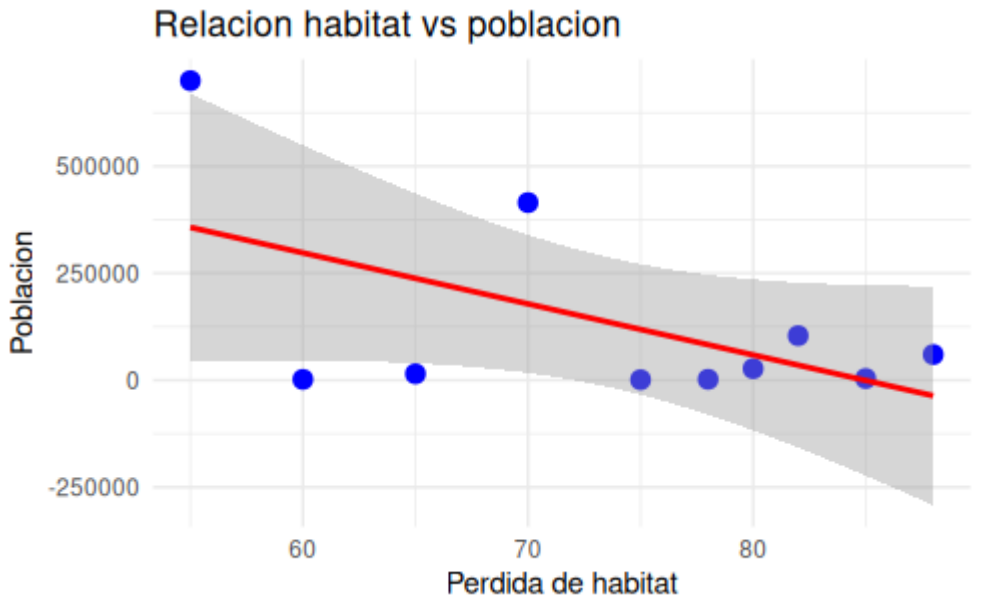

Conclusión

En conclusión, el proceso desarrollado integra diferentes etapas de la ciencia de datos, desde la preparación y exploración de los datos hasta la implementación de modelos predictivos; cada decisión metodológica, desde la selección de variables hasta el tipo de visualización y modelo utilizado, responde a la necesidad de comprender y comunicar de manera efectiva un problema ambiental complejo; este enfoque no solo permite interpretar la situación actual, sino también anticipar posibles escenarios, lo cual resulta fundamental para la toma de decisiones en contextos de sostenibilidad y conservación.

Referencias

Contexto ambiental (extinción de especies)

- International Union for Conservation of Nature. (2023). The IUCN Red List of Threatened Species. https://www.iucnredlist.org/
- World Wildlife Fund. (2022). Living Planet Report 2022: Building a nature-positive society. https://www.worldwildlife.org/
- United Nations Environment Programme. (2021). Making peace with nature: A scientific blueprint to tackle the climate, biodiversity and pollution emergencies. https://www.unep.org/

Ciencia de datos y análisis

- An Introduction to Statistical LearningJames, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning (2nd ed.). Springer.
- Wickham, H., & Grolemund, G. (2017). R for data science: Import, tidy, transform, visualize, and model data. O'Reilly Media.

Programación en R

- R Core Team. (2023). R: A language and environment for statistical computing. R Foundation for Statistical Computing. https://www.r-project.org/

Ggplot2

- Wickham, H. (2016). ggplot2: Elegant graphics for data analysis. Springer.dplyr
- Wickham, H., François, R., Henry, L., & Müller, K. (2023). dplyr: A grammar of data manipulation. https://cran.r-project.org/

Modelo de regresión

- Applied Linear Regression Models Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). Applied linear statistical models (5th ed.). McGraw-Hill.